Projeto 1

Métodos Estatísticos para Inteligência Artificial

Grupo 5:

[redacted] – [redacted]

[redacted] – [redacted]

[redacted] – [redacted]

[redacted] – [redacted]

Vasco Caetano – [redacted]

1. Introdução

Este projeto tem como objetivo de estudo a análise estatística da frame de dados *machines* da biblioteca *rrcov* do R, mais especificamente o subset comprimido entre *hp-3000/64* e *ibm-4331-2*. A análise pretende identificar os métodos de análise estatística mais eficientes para a caracterização deste *subset*, abordando questões de escalamento de dados, correlação e *outliers*.

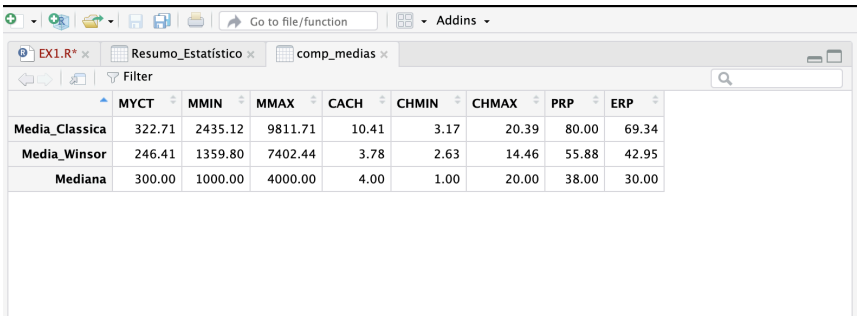
2. Objetivos de Estudo

Ao longo deste relatório aplicar-se-ão métodos de análise de componentes principais, plots e estatísticas-resumo para avaliar as propriedades distribucionais das variáveis. Isto será feito através: da comparação de métodos estatísticos clássicos com robustos para detecção de assimetrias e desvios nos dados, da análise da necessidade de estandardização dos dados através da avaliação da disparidade de escalas de variáveis e da identificação de potenciais outliers usando distâncias de *Mahalanobis* e generalizações *Z-score*. Seguidamente determinar-se-á a análise mais apropriada para este subset de dados, tendo em conta o objetivo de reduzir a dimensionalidade dos mesmos enquanto se salvaguarda uma variância total de pelo menos 95% dos dados. No fim deste estudo far-se-á a comparação do desempenho da *PCA clássica* com a *PCA robusta*, após a introdução de dados "contaminados" ao *subset* em estudo, discutindo os efeitos das observações atípicas em ambos os casos.

3. Análise Exploratória e Deteção de Anomalias

3.1 Análise de Tendência Central e Dispersão

Ao analisar inicialmente notou-se uma disparidade acentuada entre as medidas de localização clássicas e as robustas, o que sugere a forte influência de valores extremos. Verificou-se que a média *winsorizada* reduz o impacto de pontos atípicos ao substituir os valores extremos, o que oferece uma visão mais estável do centro dos dados. A tabela abaixo ilustra esta divergência:

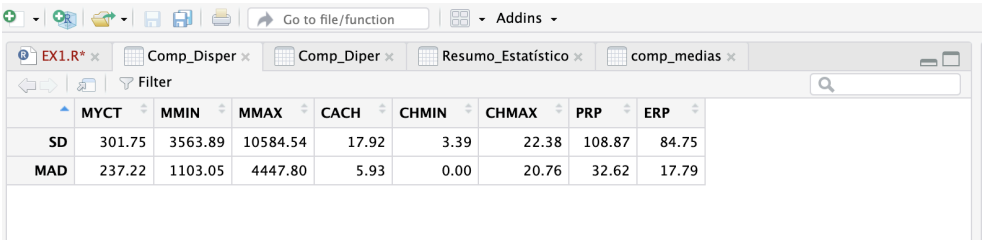


	MYCT	MMIN	MMAX	CACH	CHMIN	CHMAX	PRP	ERP
Media_Classica	322.71	2435.12	9811.71	10.41	3.17	20.39	80.00	69.34
Media_Winsor	246.41	1359.80	7402.44	3.78	2.63	14.46	55.88	42.95
Mediana	300.00	1000.00	4000.00	4.00	1.00	20.00	38.00	30.00

Fig. 1 Resultados média, média winsorizada e mediana para variáveis em estudo.

Quanto à variável *MMIN,* a sua média clássica (2435.12) é substancialmente superior em comparação com a mediana (1000) e com a média *winsorizada* (1359.80). Este facto indica uma distribuição fortemente assimétrica à direita, onde um pequeno número de máquinas inflaciona a média, distorcendo a percepção do valor central.

O Desvio Padrão (*SD*), por ser sensível a *outliers*, é superior ao Desvio Absoluto Mediano (*MAD*), uma medida robusta, como se pode observar na figura abaixo:



	MYCT	MMIN	MMAX	CACH	CHMIN	CHMAX	PRP	ERP
SD	301.75	3563.89	10584.54	17.92	3.39	22.38	108.87	84.75
MAD	237.22	1103.05	4447.80	5.93	0.00	20.76	32.62	17.79

Fig. 2 Resultados desvio padrão e desvio absoluto mediano para variáveis em estudo.

Para *MMAX*, o *SD* de 10584.54 é mais do dobro do *MAD* de 4447.80, confirmando que a variabilidade clássica está inflacionada por valores extremos.

Globalmente, a Variância Total do *dataset* (~1.25e8) e a Variância Generalizada (~2.75e29) são extremamente elevadas.

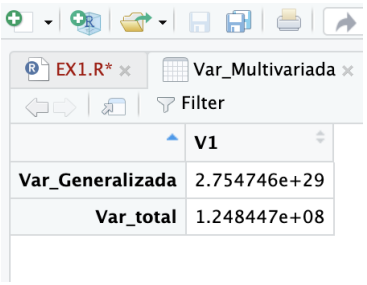


Fig. 3 Variância multivariada para as variáveis em estudo.

A Variância Total é dominada pelas variáveis (*MMIN* e *MMAX*). Esta constatação por si só invalida a aplicação de *PCA* sobre a matriz de covariância.

3.2 Deteção e Caracterização de *Outliers*

Para uma deteção formal de anomalias, foram utilizadas as Distâncias de *Mahalanobis* robustas, que se trata de uma generalização multivariada do *Z-score* que tem em conta a estrutura de correlação dos dados para medir a distância de cada ponto ao centro da distribuição.

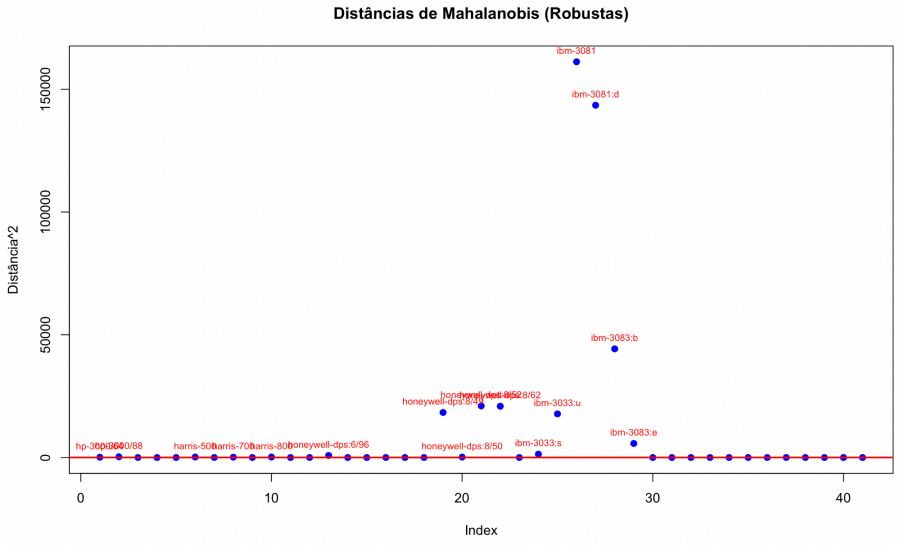


Fig. 4 Gráfico de "Distâncias de Mahalanobis (Robustas)".

O gráfico de Distâncias de *Mahalanobis* (Robustas) mostra as máquinas *ibm-3081* e *ibm-3081:d* como os *outliers* multivariados mais severos. As suas distâncias ao centro da nuvem de dados são de ordens de magnitude superiores às das restantes, tal como se pode observar.

Esta conclusão é reforçada pela análise dos gráficos *QQ-Plot*. Nos gráficos para *MMIN, PRP* e *CACH*, as observações identificadas com os índices 26 e 27, máquinas *ibm-3081* e *ibm-3081:d* respetivamente, desviam-se acentuadamente da linha de referência de normalidade teórica, confirmando visualmente o seu comportamento atípico.

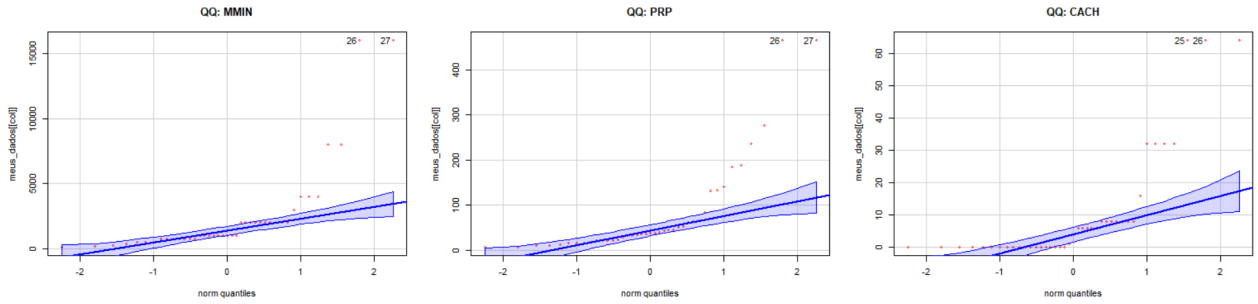


Fig. 5 Gráficos QQ-Plot para as variáveis MMIN, PRP e CACH.

Estas disparidades de escala e a confirmação de pontos atípicos multivariados requerem um pré-processamento dos dados antes de aplicar a Análise de Componentes Principais

4. Análise de Componentes Principais (PCA) para Redução de Dimensionalidade

4.1 Justificação da Abordagem Baseada na Matriz de Correlação

Para este *dataset*, a única abordagem metodologicamente válida é a realização da *PCA* sobre as variáveis padronizadas (matriz de correlação). A aplicação da *PCA* sobre a matriz de covariância conduziria a conclusões fundamentalmente erradas.

A justificação reside na manifesta incompatibilidade de unidades e escalas das variáveis originais (p.ex., nanossegundos para *MYCT* vs. *kilobytes* para *MMAX*). A comparação dos *biplots* ilustra perfeitamente este ponto:

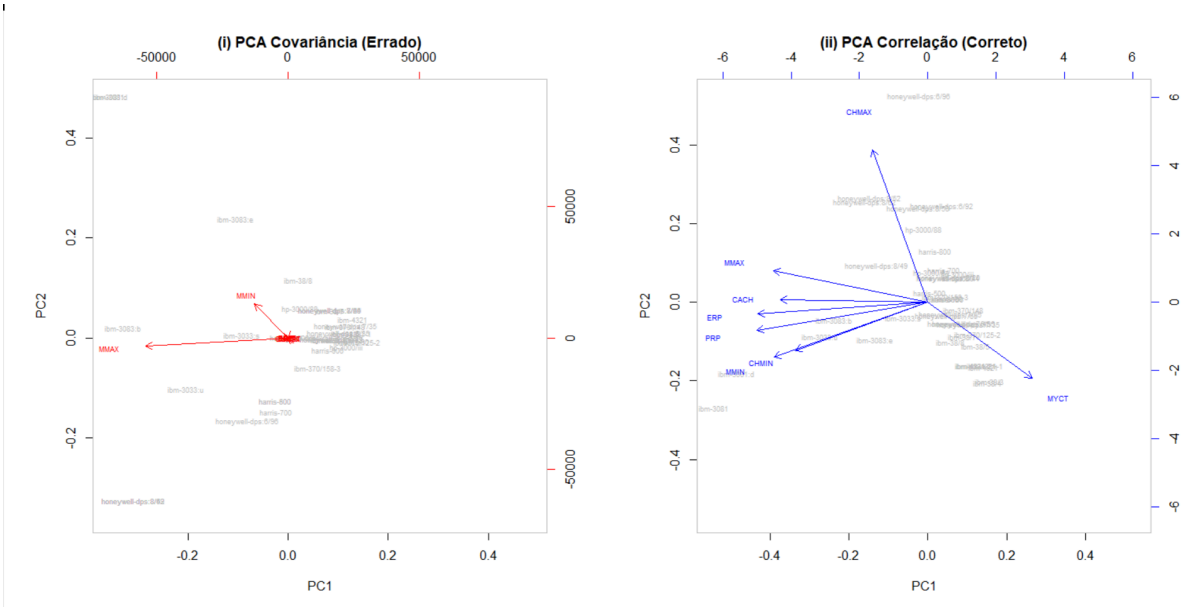


Fig. 6 Gráficos de análise da PCA: Covariância e Correlação.

- **(i) PCA de Covariância (Errado)**: Os vetores de *MMIN* e *MMAX* monopolizam a primeira componente, tornando os vetores das restantes variáveis tão insignificantes que são visualmente indistinguíveis da origem.
- **(ii) PCA de Correlação (Correto)**: A padronização equilibra o peso de todas as variáveis, permitindo detetar a verdadeira estrutura dos dados independentemente da escala. Assim, o *biplot* resultante mostra uma distribuição equilibrada e revela a oposição fundamental entre *MYCT* e as variáveis de performance/memória (*PRP, MMAX*), o que representa visualmente o compromisso entre tempo de ciclo e a potência geral da máquina.

4.2 Seleção e Interpretação das Componentes Principais

Como se deve adotar o critério de reter pelo menos 95% da variância total dos dados, tem de se somar as proporções até ultrapassar 0.95. Neste caso, tal é possível ao selecionar os 5 componentes principais, pois 0.97 > 0.95.

```
> resumo
Importance of components:
                          PC1    PC2     PC3     PC4     PC5     PC6     PC7     PC8
Standard deviation     2.277 1.0905 0.82613 0.64577 0.55411 0.44252 0.13098 0.08641
Proportion of Variance 0.648 0.1487 0.08531 0.05213 0.03838 0.02448 0.00214 0.00093
Cumulative Proportion  0.648 0.7966 0.88194 0.93406 0.97244 0.99692 0.99907 1.00000
```

Fig.7 Desvio padrão, proporção de variância e proporção cumulativa das componentes principais

- ***PC1**:* **Eixo de Capacidade e Performance Bruta:** Esta componente captura a primeira componente de investimento numa máquina: potência e memória. É crucial notar que o *loading* de *MYCT* (0.261) é positivo, o que significa que valores mais altos de PC1 estão associados a tempos de ciclo mais lentos. Em contraste, os *loadings* fortemente negativos para performance (*PRP*: -0.429) e memória (*MMAX*: -0.387) indicam que valores *negativos* em PC1 representam as máquinas mais potentes. A componente, portanto, separa efetivamente os sistemas de alta e baixa performance ao longo do seu eixo.
- ***PC2**: **Eixo de Especialização Arquitetónica**:* A segunda componente é dominada por um loading fortemente positivo de *CHMAX* (0.800) e um loading negativo de *MYCT* (-0.399). Esta componente representa um eixo de especialização na arquitetura da máquina. Uma máquina pode obter um score positivo nesta componente ao especializar-se em débito de I/O (elevado *CHMAX*), ou um score negativo ao especializar-se em velocidade de processamento pura (baixo *MYCT*). Isto reflete um compromisso de design estratégico, separando máquinas com alta capacidade de canais daquelas com tempos de ciclo mais rápidos.

4.3 Visualização e Validação dos Scores

O gráfico *PCA Scores*, que projeta as observações no plano definido pelas duas primeiras componentes, valida visualmente estas interpretações. As máquinas *ibm-3081* e *ibm-3081:d* localizam-se no extremo esquerdo do eixo horizontal (PC1), com os scores mais negativos.

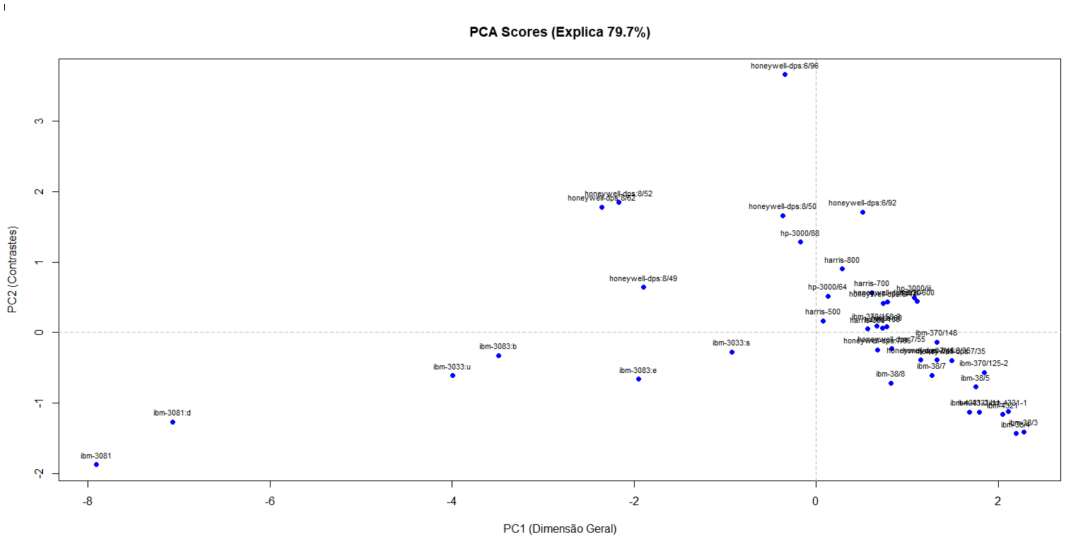


Fig. 8 Gráfico dos scores da PCA.

Esta confirmação visual é crucial: demonstra que as Distâncias de *Mahalanobis* identificaram corretamente não erros anómalos, mas sim os sistemas de mais alta especificação do dataset, cujas características definem o limite superior de performance nesta amostra. A *PCA*, portanto, não só valida a análise de *outliers* como também lhe confere um significado prático.

5. Análise de robustez da PCA: Impacto do Ponto Atípico

5.1 Introdução do ponto atípico e preparação do conjunto de dados

Quanto à questão 2 utilizou-se o vetor do enunciado para a máquina *hp-3000/64* com os valores (75, 2000, 0.8, 8000, 300, 24, 62, 47). Verificou-se que no 3º valor, onde *MMAX* = 0.8 enquanto *MMIN* = 2000, existe uma inconsistência.

Foram aplicados dois métodos *PCA Clássica*, sensível a *outliers*, usando prcomp e *PCA Robusta* utilizando o estimador *MCD* através da função *PcaCov* do pacote *rrcov*.

No gráfico da *PCA clássica*, o ponto atípico absorveu praticamente toda a variância, "esmagando" a visualização. Já a *PCA* robusta corrige este problema, mantendo uma estrutura visual interpretável.

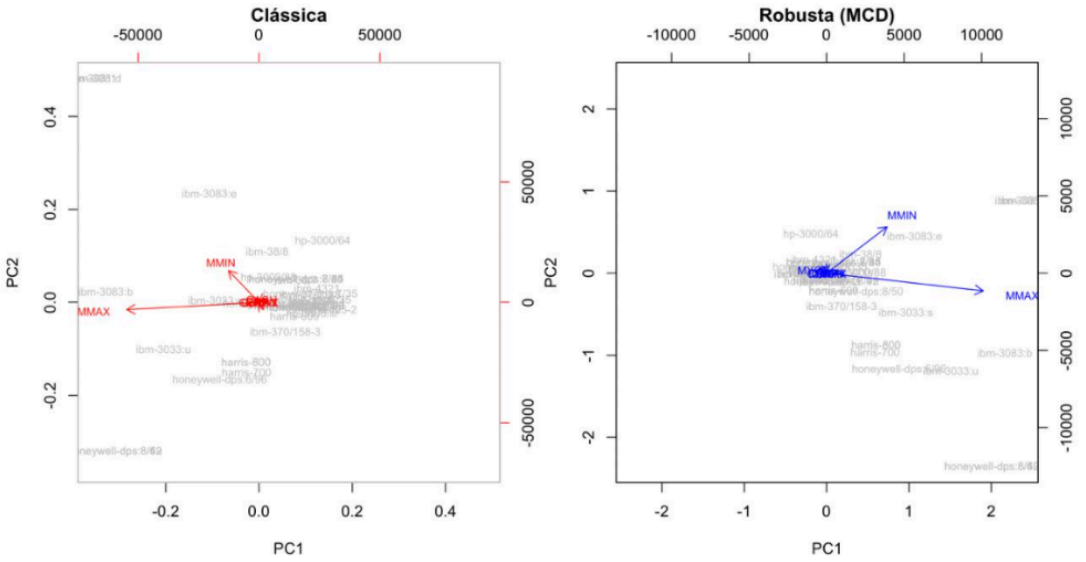


Fig. 9 Comparação entre PCA clássica e PCA robusta

5.1 (a) Análise da PCA clássica

Como se pode observar no gráfico da esquerda da figura 9, existe uma alta sensibilidade da *PCA clássica* à presença de um *outlier*.

Isso é evidente devido a vários fatores presentes na figura como a posição extremamente distante do *outlier* inserido (*hp-3000/64*) ao centro e à maioria dos pontos, que por sua vez também tem implicações estatísticas diretas, nomeadamente:

- **Influência na escala:** O *outlier* influencia a escala, o que enviesa o *PC1*, uma vez que este por definição deveria procurar a maior variabilidade intrínseca entre as máquinas, ou seja as diferenças normais entre as máquinas, mas é influenciado a apontar na direção do ponto atípico. Assim, o *PC1* passa a representar principalmente a atipicidade, isto é a diferença introduzida pelo ponto singular e não a estrutura de dispersão de dados.
- **Compressão da estrutura:** Invalida também qualquer análise detalhada das relações entre as variáveis ou dos possíveis agrupamentos entre as máquinas que não são *outliers*, devido à ampla diferença de escala que este ponto único impõe ao gráfico, consequentemente o resto das observações ficam extremamente comprimidas e agrupadas junto à origem (0,0).

Concluindo a *PCA clássica* ao ser baseada em métodos não robustos (média e covariâncias clássicas) não é capaz de cumprir a sua missão de resumir a variabilidade dos dados de forma fidedigna, a análise torna-se contaminada, refletindo a presença do *outlier* em vez da estrutura válida das observações.

5.1 (b) Análise da PCA Robusta

Em contraste com a análise clássica, é evidente no gráfico da direita a elevada robustez da *PCA*, baseada no *MCD* (minimum covariance determinant), que demonstra que este método é capaz de isolar o *outlier* e principalmente preservar a estrutura da covariância da maioria dos dados.

- **Fundamentação do MCD:** A robustez do método reside no facto de o estimador *MCD* operar identificando o subconjunto de observações que possui o determinante da matriz de covariância mais pequeno. Este subconjunto é, por definição, o mais compacto e menos disperso, excluindo o *outlier* da estimativa da matriz de dispersão. Desta forma, o efeito de uma observação atípica na *PCA* Robusta é o oposto do que se vê na *PCA Clássica*.
- **Estabilidade:** Ao contrário do *PC1*, a *PCA* robusta mantém as direções dos componentes principais, semelhantes às encontradas nos dados originais (antes da

contaminação), o que significa que o *MCD* identificou e atribuiu um peso muito reduzido (ou nulo) ao *outlier* no cálculo da matriz de dispersão.

- **Preservação da Estrutura:** O agrupamento principal de dados encontra-se agora claramente disperso e com uma estrutura de dados bem definida, sem estar massivamente comprimido junto à origem (0,0). Isto é fundamental, pois permite que a dispersão no plano *PC1-PC2* reflita a variabilidade intrínseca e verdadeira das observações não atípicas.
- **Isolamento do *Outlier*:** Embora a observação *hp-3000/64* continue a destacar-se como um ponto de alta distância robusta, a sua posição não distorce a escala nem o cálculo dos eixos principais, assim a *PCA* robusta cumpre o seu papel de isolar o ponto atípico sem comprometer a representação dos dados válida.

Concluindo, a *PCA Robusta* (MCD) ignora efetivamente a observação contaminada *hp-3000/64* ao calcular a estrutura principal dos dados. Isto significa que os autovalores e os componentes principais (direções) obtidos pela *MCD* são muito mais próximos daqueles que seriam obtidos na amostra original sem o *outlier*.

5.2 Verificação Numérica da *PCA Clássica* vs *PCA Robusta*

Comparámos a proporção de variância explicada pelo primeiro componente principal (*PC1*) em ambas as abordagens. A *PCA clássica* mostrou 93.326% de variância em *PC1*, evidenciando o domínio do *outlier.* Em contraste, a *PCA robusta* apresentou 89.76%, um valor mais equilibrado que demonstra resistência à contaminação.

A *PCA Robusta* (*MCD*) é, portanto, a decisão correta para a redução de dimensão e interpretação de dados quando a contaminação por *outliers* é uma preocupação.

6. Conclusões

A análise do subconjunto *machines* evidenciou a importância crítica de adequar os métodos estatísticos à forte heterogeneidade e assimetria dos dados. A aplicação de estimadores robustos (como a média winsorizada e o estimador MCD) e a padronização das variáveis revelaram-se passos indispensáveis, uma vez que a disparidade de escalas e a presença de valores extremos inflacionaram as métricas clássicas e enviesaram a PCA baseada na covariância. Através da *PCA* sobre a matriz de correlação, foi possível sintetizar a estrutura latente dos dados nas dimensões de "Potência Bruta" e "Especialização de Arquitetura", confirmando que os *outliers* multivariados identificados (família *ibm-3081*) não constituem anomalias de erro, mas representam, de facto, o segmento tecnológico de maior

performance da amostra. Em suma, o estudo valida a coerência entre a deteção de anomalias e a redução de dimensionalidade na caracterização de sistemas computacionais de topo.

A *PCA* Clássica falha em cumprir a sua missão de resumir a variabilidade fidedigna dos dados quando confrontada com *outliers*. A observação contaminada (*hp-3000/64*) distorce severamente os estimadores clássicos de média e covariância, levando a que as componentes principais e os respectivos autovalores reflitam a anomalia em vez da estrutura subjacente da maioria das observações. Em contraste, a *PCA* Robusta (*MCD*) demonstra ser essencial, pois ignora eficazmente a influência do *outlier* no cálculo da estrutura principal. Ao fazê-lo, a *PCA* Robusta fornece uma descrição muito mais fidedigna e estável da variabilidade dos dados, permitindo uma interpretação estatística válida.

7. Bibliografia

Rodrigues, I. M. [redacted]. MEIA - Chapter 1: Exploratory Data Analysis [Slides de aula]. Departamento de Matemática, Instituto Superior Técnico .

Rodrigues, I. M. [redacted]. MEIA - Chapter 2: Dimensionality reduction: principal component analysis [Slides de aula]. Departamento de Matemática, Instituto Superior Técnico .

Rodrigues, I. M. [redacted]. Principal Components Analysis [Apontamentos manuscritos]. Departamento de Matemática, Instituto Superior Técnico .

Rodrigues, I. M. (2023). Food Price Data PCA in R (PCA-in-R_Ex-8) [Guião de Laboratório R]. Departamento de Matemática, Instituto Superior Técnico .